



Pós-graduação em Applied AI & ML

Time Series Forecasting

Jorge Caiado

2025/2026 (5ª Edição)

Triple Crown Accreditation



Top 40
Worldwide
Knowledge to Shape the Future



**EXECUTIVE
EDUCATION**

Tópicos:

- Introdução às séries temporais. Método de decomposição
- Métodos de alisamento exponencial
- Modelos ARMA, SARMA, ARIMA e SARIMA
- Metodologia de modelação e previsão ARIMA/SARIMA
- Modelos ARIMAX e SARIMAX com variáveis exógenas
- Redes neuronais convolucionais (CNN)
- Redes neuronais recorrentes (RNN)
- Memória de curto prazo longa (LSTM)
- Unidade recorrente com portas (GRU)




Aula #0

Introdução às séries temporais. Métodos de decomposição

O que é uma série temporal?

Uma **série temporal** (*time series*) consiste num conjunto de observações de uma variável, feitas em períodos sucessivos de tempo, durante um determinado intervalo. São exemplos, a cotação diária das ações da Google, a venda semanal de um dado produto, o número mensal de dormidas na hotelaria, o lucro anual de uma empresa, a temperatura mínima, média e máxima diária.

A representação gráfica de uma série temporal designa-se por **cronograma** e constitui o ponto de partida para a sua análise. Nas figuras seguintes apresentam-se os cronogramas das séries de produção mensal de cerveja na Austrália entre janeiro de 1956 e agosto de 1995, as cotações diárias de fecho ajustadas (em dólares) das ações da Microsoft na bolsa de Nova Iorque entre 1/01/2015 e 31/12/2022, e as vendas de champagne Perrin Freres entre 1964 e 1972.



Como interpreta estes gráficos?

Quais os principais padrões observados?

Método de decomposição de séries temporais

A **tendência** caracteriza o andamento mais notório da série durante um longo período de tempo.

Os **movimentos oscilatórios ou cíclicos** estão associados às fases de expansão e recessão dos sistemas económicos.

A **sazonalidade** refere-se às oscilações periódicas que ocorrem semanalmente, mensalmente ou trimestralmente no decurso do ano.

Os **movimentos irregulares ou aleatórios** são os movimentos da série que não são explicados pelas componentes anteriormente referidas.

O modelo de decomposição pode traduzir-se pela seguinte expressão:

$$Y_t = f(T_t, S_t, R_t),$$

onde a série Y_t é função da componente de tendência-cíclica (*trend-cycle*) T_t , da componente sazonal (*seasonal*) S_t e da componente irregular ou residual (*noise*) R_t .

Modelo aditivo

1. Estimação da **tendência** (T_t):

$$T_t = (0.5Y_{t-6} + Y_{t-5} + \dots + Y_t + \dots + Y_{t+5} + 0.5Y_{t+6})/12 \text{ (dados mensais)}$$

$$T_t = (0.5Y_{t-2} + Y_{t-1} + Y_t + Y_{t+1} + 0.5Y_{t+2})/4 \text{ (dados trimestrais)}$$

2. Eliminação dos movimentos de tendência-cíclicos: $D_t = Y_t - T_t$



3. Obtenção dos índices sazonais: $I_j = (1/N) \times (D_{1,j} + D_{2,j} + \dots + D_{N,j})$, $j = 1, 2, \dots, s$. Em seguida, calculamos os **fatores sazonais** (S_j):

$$S_j = I_j - (I_1 + I_2 + \dots + I_{12})/12, j = 1, 2, \dots, 12 \text{ (dados mensais)}$$

$$S_j = I_j - (I_1 + I_2 + I_3 + I_4)/4, j = 1, 2, 3, 4 \text{ (dados trimestrais)}$$

4. Construção da **série residual ou ruído** (R_t): $R_t = Y_t - T_t - S_t$

Exemplo: Crie uma série mensal de vendas com sazonalidade (dados fictícios) e extraia as suas forças componentes (mod. aditiv.)



Modelo multiplicativo

1. Estimação da **tendência** (T_t):

$$T_t = (0.5Y_{t-6} + Y_{t-5} + \dots + Y_t + \dots + Y_{t+5} + 0.5Y_{t+6})/12 \text{ (dados mensais)}$$

$$T_t = (0.5Y_{t-2} + Y_{t-1} + Y_t + Y_{t+1} + 0.5Y_{t+2})/4 \text{ (dados trimestrais)}$$

2. Eliminação dos movimentos de tendência-cíclicos: $Q_t = Y_t/T_t$


3. Obtenção dos índices sazonais: $I_j = (1/N) \times (Q_{1,j} + Q_{2,j} + \dots + Q_{N,j})$, $j = 1, 2, \dots, s$. Em seguida, calculamos os **fatores sazonais** (S_j):

$$S_j = I_t / \sqrt[12]{I_1 I_2 \dots I_{12}}, j = 1, 2, \dots, 12 \text{ (dados mensais)}$$

$$S_j = I_t / \sqrt[4]{I_1 I_2 I_3 I_4}, j = 1, 2, 3, 4 \text{ (dados trimestrais)}$$

4. Construção da **série residual ou ruído** (R_t): $R_t = Y_t/(T_t \times S_t)$

Exemplo: Passageiros aéreos



Exercícios:

1. Considere os dados das vendas mensais de champagne Perrin Freres em França, no período de janeiro de 1964 a setembro de 1972, disponíveis através do link:

https://raw.githubusercontent.com/jbrownlee/Datasets/master/monthly_champagne_sales.csv

- a) Use o método de decomposição multiplicativo para isolar as componentes da série
- b) Como poderia detetar e remover potenciais *outliers* na série observada? **Sugestão:** Use a série residual e considere 2 desvios padrão da média como valor limite para identificar os *outliers*.

Aula #1

Métodos de alisamento exponencial

O que é o alisamento exponencial?

São métodos estatísticos de previsão que utilizam combinações ponderadas das observações passadas para prever os valores futuros.


O termo “**alisamento exponencial**” significa que os ponderadores são exponencialmente decrescentes com a antiguidade das observações.

Nesta secção são exploradas as diversas abordagens dos métodos de alisamento exponencial em problemas de previsão: **Simples**, **Holt** e **Holt-Winters** (aditivos e multiplicativo).

Em termos práticos, podemos considerar duas formas de avaliar a qualidade preditiva: previsão passo-a-passo (ou **previsão estática**) e previsão a múltiplos passos à frente (**previsão dinâmica**).

Exemplo: Previsões estática e dinâmica baseadas nas médias das últimas 3 observações das vendas mensais de uma empresa em 2022: [30, 25, 40, 37, 55, 60, 64, 65, 70, 75, 82, 87]. Amostra de treino: primeiras 9 observações (75% do total). Amostra de teste: últimas 3 observações (25% do total).

Data	Vendas	Previsões dinâmicas	Previsões estáticas
2022-10-31	75	66.333333	66.333333
2022-11-30	82	66.333333	70.000000
2022-12-31	87	66.333333	75.666667



Avaliação dos Erros de Previsão

Erro quadrático médio (EQM). Traduz o valor médio dos desvios ao quadrado entre os valores observados e as previsões para os instantes 1, 2,..., m :

$$EQM = \frac{1}{m} \sum_{t=1}^m (Y_t - P_t)^2 \text{ e } REQM = \sqrt{EQM}.$$

Erro absoluto médio (EAM). Traduz o valor absoluto médio dos desvios entre os valores observados e as previsões para os instantes 1, 2,..., m :

$$EAM = \frac{1}{m} \sum_{t=1}^m |Y_t - P_t|.$$

Erro percentual absoluto médio (EPAM). Traduz o valor percentual absoluto médio dos desvios entre os valores observados e as previsões para os instantes 1, 2,..., m :

$$EPAM = \frac{1}{m} \sum_{t=1}^m \left| \frac{(Y_t - P_t)}{Y_t} \right| \times 100.$$

Erro Percentual Absoluto Médio Simétrico (EPAMs):

$$EPAMs = \frac{1}{m} \sum_{t=1}^m \frac{|(Y_t - P_t)|}{|Y_t| + |P_t|} \times 200\%.$$

```
Erros de Previsão Dinâmica:
RMSE (Previsões Dinâmicas): 15.79
MAE (Previsões Dinâmicas): 15.00
MAPE (Previsões Dinâmicas): 18.14%
sMAPE (Previsões Dinâmicas): 19.43%
```

```
Erros de Previsão Estática:
RMSE (Previsões Estáticas): 10.76
MAE (Previsões Estáticas): 10.67
MAPE (Previsões Estáticas): 13.07%
sMAPE (Previsões Estáticas): 14.00%
```

Alisamento Exponencial Simples

Séries com tendência localmente estacionária e sem movimentos sazonais.

Para obter previsões para o instante $t + 1$, o método de **alisamento exponencial simples** utiliza a previsão do último instante ajustada pelo respetivo erro de previsão, através da expressão:

$$P_{t+1} = P_t + \alpha(Y_t - P_t) = \alpha Y_t + (1 - \alpha)P_t,$$

onde α é uma constante de amortecimento ou alisamento que varia entre 0 e 1.

Para arrancar com o processo de previsão, deve escolher-se um **valor inicial** para P_1 (em geral, Y_1) e um valor para a **constante de alisamento** α (em geral, aquele que minimiza o REQM).

As **previsões** são constantes para todo o horizonte temporal, isto é:

$$P_{t+h} = P_{t+1}, h = 2, 3, \dots$$

Exemplo: Vendas de leitores DVD “Super Tech” (em milhares de unidades) por parte de uma empresa americana, em 161 semanas consecutivas (Fonte: Bowerman, O'Connell e Koehler, 2005). Fazendo uma divisão de 80:20 para as amostras de treino e teste, vamos aplicar o método de alisamento simples com a **escolha ótima** da constante de alisamento e com a **escolha manual** ($\alpha = 0.15$).

```
data = {'Data': pd.date_range(start='2000-01', periods=161, freq='W'),
        'Vendas': [45.9, 45.4, 42.8, 34.4, 31.9, 36.6, 39.2, 41.4, 40.3, 43.1, 43.2, 41.2, 38.4,
                    38.3, 41.9, 37.1, 34.5, 31.3, 30.2, 28.3, 25.9, 26.6, 26.2, 29.0, 34.8, 36.8, 37.2, 41.7,
                    41.2, 40.7, 39.5, 40.4, 38.0, 35.6, 33.9, 35.2, 41.8, 42.4, 38.9, 42.1, 41.7, 39.2, 38.5,
                    42.5, 47.9, 48.6, 52.0, 53.5, 53.5, 52.9, 53.4, 52.8, 51.4, 52.5, 52.4, 51.5, 51.7, 53.3,
                    55.4, 56.9, 60.0, 60.8, 62.3, 62.6, 63.1, 62.8, 64.7, 66.3, 63.0, 65.5, 70.6, 76.0, 80.1,
                    78.6, 78.3, 78.1, 73.6, 68.8, 64.4, 62.4, 61.1, 63.1, 65.3, 68.3, 72.5, 73.2, 72.9, 70.5,
                    69.4, 68.2, 69.3, 72.3, 73.5, 70.3, 68.3, 64.1, 62.5, 62.6, 60.4, 61.1, 64.7, 65.1, 61.5,
                    64.2, 67.8, 66.8, 64.1, 66.4, 68.0, 71.0, 76.9, 84.1, 85.9, 85.2, 86.2, 85.7, 81.3, 75.9,
                    75.0, 72.5, 69.6, 67.3, 69.8, 72.2, 75.2, 77.2, 76.8, 72.4, 69.4, 68.7, 65.1, 64.4, 64.2,
                    63.2, 62.1, 65.8, 73.7, 77.1, 76.0, 74.6, 70.6, 67.5, 67.9, 68.9, 67.8, 65.1, 65.0, 67.6,
                    67.9, 66.5, 68.2, 71.7, 71.3, 68.9, 70.0, 73.1, 69.1, 67.3, 72.9, 78.6, 82.3]}
```

Valor ótimo de alpha: 1.0000

Resultados de otimização:


SimpleExpSmoothing Model Results

```
=====
Dep. Variable:          Vendas      No. Observations:          128
Model:                SimpleExpSmoothing      SSE          986.130
Optimized:              True      AIC          265.345
Trend:                  None      BIC          271.049
Seasonal:              None      AICC         265.670
Seasonal Periods:      None      Date:          Fri, 19 Apr 2024
Box-Cox:                False      Time:         10:59:06
Box-Cox Coeff.:        None
=====
              coeff              code              optimized
-----
smoothing_level      1.0000000      alpha              True
initial_level        45.900000      1.0                True
-----
```


Raiz do erro quadrático médio (RMSE) do AES com alpha ótimo: 5.40
 Erro absoluto médio (MAE) do AES com alpha ótimo: 4.69
 Erro percentual absoluto médio (MAPE) do AES com alpha ótimo: 6.89%

Raiz do erro quadrático médio (RMSE) do AES com alpha = 0.15: 6.64
 Erro absoluto médio (MAE) do AES com alpha = 0.15: 5.88
 Erro percentual absoluto médio (MAPE) do AES com alpha = 0.15: 8.71%

Previsões de vendas de DVD com alisamento exponencial simples (AES)



Previsões de vendas de DVD com alisamento exponencial simples (AES)



Método de Holt

Séries com tendência linear e sem movimentos de carácter sazonal.

Este método de previsão utiliza as seguintes equações de atualização:

$$a(t) = \alpha Y_t + (1 - \alpha)[a(t - 1) + b(t - 1)], 0 < \alpha < 1$$

$$b(t) = \beta[a(t) - a(t - 1)] + (1 - \beta)b(t - 1), 0 < \beta < 1$$

onde $a(t)$ e $b(t)$ são as equações de atualização do nível e do declive da série, respetivamente, e α e β são as constantes de alisamento.

As previsões a h passos à frente são obtidas através da função:

$$P_{t+h} = a(t) + b(t) \times h, h = 1, 2, \dots$$

Para inicializar $a(1)$ e $b(1)$, pode usar as expressões:

$$b(1) = \frac{\bar{Y}_2 - \bar{Y}_1}{k} \quad \text{e} \quad a(1) = \bar{Y}_1 - b(1) \times \frac{k+1}{2},$$

onde $\bar{Y}_1$ é a média das primeiras k observações da série e $\bar{Y}_2$ a média das k observações seguintes.

Valor ótimo de alpha: 1.0000
 Valor ótimo de beta: 0.0000

Resultados de otimização:


ExponentialSmoothing Model Results

```
=====
Dep. Variable:          Vendas      No. Observations:          144
Model:          ExponentialSmoothing      SSE          1125.221
Optimized:          True      AIC          304.053
Trend:          Additive      BIC          315.932
Seasonal:          None      AICC          304.666
Seasonal Periods:          None      Date:          Fri, 19 Apr 2024
Box-Cox:          False      Time:          11:06:48
Box-Cox Coeff.:          None
=====
```


	coeff	code	optimized
smoothing_level	1.0000000	alpha	True
smoothing_trend	0.0000000	beta	True
initial_level	45.739179	l.0	True
initial_trend	0.1608371	b.0	True

Raiz do erro quadrático médio (RMSE) do Holt com alpha e beta ótimos: 3.88
 Erro absoluto médio (MAE) do Holt com alpha e beta ótimos: 2.99
 Erro percentual absoluto médio (MAPE) do Holt com alpha e beta ótimos: 4.16%

Previsões de vendas de DVD com o método de Holt



Previsões de vendas de DVD com o método de Holt



Método de Holt-Winters

Séries que apresentam tendência linear e movimentos sazonais.

Na forma **multiplicativa**, o método de Holt-Winters é definido pelas seguintes equações de actualização:

$$a(t) = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)[a(t-1) + b(t-1)], 0 < \alpha < 1$$

$$b(t) = \beta[a(t) - a(t-1)] + (1 - \beta)b(t-1), 0 < \beta < 1$$

$$S_t = \gamma \frac{Y_t}{a(t)} + (1 - \gamma)S_{t-s}, 0 < \gamma < 1,$$

onde $a(t)$, $b(t)$ e S_t representam as expressões do nível, do declive e do índice sazonal, respectivamente; e α , β e γ são as constantes de alisamento.

As previsões a h passos à frente do método de Holt-Winters multiplicativo são obtidas através da função:

$$P_{t+h} = [a(t) + b(t) \times h] \times S_{t+h-s}, h = 1, 2, \dots$$

Para inicializar o nível, calcula-se a média das primeiras s observações:

$$a(s) = (1/s) \sum_{t=1}^s Y_t.$$

Para inicializar o valor do declive, utiliza-se a expressão:

$$b(s) = (1/s^2) (\sum_{t=s+1}^{2s} Y_t - \sum_{t=1}^s Y_t).$$

E por último, os primeiros índices sazonais são obtidos por:

$$S_1 = Y_1/a(s), S_2 = Y_2/a(s), \dots, S_s = Y_s/a(s).$$

Exemplo: Série do número mensal de passageiros aéreos internacionais (em milhares) de Janeiro de 1949 a Dezembro de 1960 (Fonte: Box, Jenkins, Reinsel e Ljung, 2015):

```
import pandas as pd
url = "https://raw.githubusercontent.com/jbrownlee/Datasets/master/airline-
passengers.csv"
df = pd.read_csv(url)
df['Month'] = pd.to_datetime(df['Month'])
df.set_index('Month', inplace=True)
```

Valor ótimo de alpha: 0.3642
 Valor ótimo de beta: 0.0000
 Valor ótimo de gamma: 0.6358

Resultados de otimização:

ExponentialSmoothing Model Results


```


=====
Dep. Variable:          Passengers    No. Observations:          120
Model:                ExponentialSmoothing    SSE                10764.240
Optimized:              True            AIC                571.579
Trend:                  Additive         BIC                616.179
Seasonal:               Multiplicative    AICC               578.351
Seasonal Periods:        12             Date:              Wed, 17 Apr 2024
Box-Cox:                 False           Time:              14:06:12
Box-Cox Coeff.:          None
=====
  
```

	coeff	code	optimized
smoothing_level	0.3642233	alpha	True
smoothing_trend	5.9072e-11	beta	True
smoothing_seasonal	0.6357767	gamma	True
initial_level	194.62939	l.0	True
initial_trend	4.1934356	b.0	True
initial_seasons.0	0.5633153	s.0	True
initial_seasons.1	0.5920621	s.1	True
initial_seasons.2	0.6507722	s.2	True
initial_seasons.3	0.6192757	s.3	True
initial_seasons.4	0.5732550	s.4	True
initial_seasons.5	0.6292575	s.5	True
initial_seasons.6	0.6861762	s.6	True
initial_seasons.7	0.6780071	s.7	True
initial_seasons.8	0.6185419	s.8	True
initial_seasons.9	0.5388900	s.9	True
initial_seasons.10	0.4786357	s.10	True
initial_seasons.11	0.5516435	s.11	True

Raiz do erro quadrático médio (RMSE) com alpha, beta e gamma ótimos: 32.49
 Erro absoluto médio (MAE) do Holt-Winters com alpha, beta e gamma ótimos: 28.98
 Erro percentual absoluto médio (MAPE) com alpha, beta e gamma ótimos: 6.39%

Previsões de passageiros aéreos com o Holt-Winters multiplicativo





Quando a amplitude das variações sazonais da série temporal não se altera ao longo do tempo, podemos usar o **método de Holt-Winters com sazonalidade aditiva**. Este método de previsão baseia-se nas seguintes equações de atualização:

$$a(t) = \alpha(Y_t - S_{t-s}) + (1 - \alpha)[a(t - 1) + b(t - 1)], 0 < \alpha < 1$$

$$b(t) = \beta[a(t) - a(t - 1)] + (1 - \beta)b(t - 1), 0 < \beta < 1$$

$$S_t = \gamma[Y_t - a(t)] + (1 - \gamma)S_{t-s}, 0 < \gamma < 1$$

As previsões a h passos à frente do modelo de sazonalidade aditiva são obtidas através da função:

$$P_{T+h} = a(T) + b(T) \times h + S_{T+h-s}, h = 1, 2, \dots$$

A inicialização do método de Holt-Winters aditivo é igual ao método multiplicativo, excetuando os índices sazonais, cujos valores iniciais são obtidos por

$$S_1 = Y_1 - a(s), S_2 = Y_2 - a(s), \dots, S_s = Y_s - a(s).$$

Holt-Winters com sazonalidade aditiva

```

Valor ótimo de alpha: 0.2368
Valor ótimo de beta: 0.0000
Valor ótimo de gamma: 0.7632

Resultados de otimização:
ExponentialSmoothing Model Results
=====
Dep. Variable:      Passengers    No. Observations:      120
Model:      ExponentialSmoothing    SSE      16033.610
Optimized:      True    AIC      619.394
Trend:      Additive    BIC      663.994
Seasonal:      Additive    AICC      626.166
Seasonal Periods:      12    Date:      Wed, 17 Apr 2024
Box-Cox:      False    Time:      14:28:22
Box-Cox Coeff.:      None
=====

```



	coeff	code	optimized
smoothing_level	0.2367579	alpha	True
smoothing_trend	1.0333e-09	beta	True
smoothing_seasonal	0.7632421	gamma	True
initial_level	205.08218	l.0	True
initial_trend	2.2768059	b.0	True
initial_seasons.0	-95.264457	s.0	True
initial_seasons.1	-89.738647	s.1	True
initial_seasons.2	-77.202370	s.2	True
initial_seasons.3	-82.245969	s.3	True
initial_seasons.4	-90.864186	s.4	True
initial_seasons.5	-76.647503	s.5	True
initial_seasons.6	-64.360446	s.6	True
initial_seasons.7	-66.676328	s.7	True
initial_seasons.8	-80.787522	s.8	True
initial_seasons.9	-99.674554	s.9	True
initial_seasons.10	-114.39703	s.10	True
initial_seasons.11	-98.281949	s.11	True

```

Raiz do erro quadrático médio (RMSE) com alpha, beta e gamma ótimos: 35.76
Erro absoluto médio (MAE) do Holt-Winters com alpha, beta e gamma ótimos: 31.08
Erro percentual absoluto médio (MAPE) com alpha, beta e gamma ótimos: 6.64%

```

Holt-Winters com sazonalidade aditiva



Exercícios:

1. Com base no seguinte método de previsão para séries com tendência e sem sazonalidade:

$$a_t = \alpha Y_t + (1 - \alpha)[a_{t-1} + b_{t-1}], 0 < \alpha < 1$$

$$b_t = \beta[a_t - a_{t-1}] + (1 - \beta)b_{t-1}, 0 < \beta < 1$$

e nos valores $b_{23} = 5.5$, $P_{24} = 246.48$ e $Y_{24} = 266$ para $\alpha = 0.501$ e $\beta = 0.072$, estabeleça previsões para os instantes $t = 25, 26$ e 27 .

2. Considere os dados das vendas de shampoo numa mercearia, em 30 semanas consecutivas (Bowerman, O'Connell e Koehler, 2005): shampoo = [339, 319, 352, 330, 378, 392, 390, 395, 386, 383, 396, 396, 412, 387, 382, 423, 386, 420, 417, 474, 450, 444, 456, 449, 428, 444, 389, 447, 395, 417].

a) Use as últimas 5 semanas como amostra de teste e ajuste aos dados de treino o método de Holt com a pesquisa ótima das constantes de alisamento. Estabeleça previsões para o período de teste e calcule as medidas do erro quadrático médio (*EQM*) e erro percentual absoluto médio (*EPAM*).

b) Estabeleça previsões para as 5 semanas seguintes à amostra de teste.

3. Considere os dados mensais do Número de Dormidas em Hotéis, Motéis e Guesthouses em Victoria (Fonte: www.datamarket.com, Time Series Data Library) em formato DataFrame (Python):

```
import pandas as pd
data = {'Dormidas':
[276986, 260633, 291551, 275383, 275302, 231693, 238829, 274215, 277808, 299060, 286629, 232313, 294053,
267510, 309739, 280733, 287298, 235672, 256449, 288997, 290789, 321898, 291834, 241380, 295469, 258200,
306102, 281480, 283101, 237414, 274834, 299340, 300383, 340862, 318794, 265740, 326988, 300713, 346414,
317325, 326208, 270657, 278158, 324584, 321801, 343542, 354040, 278179, 330246, 307344, 375874, 335309,
339271, 280264, 293689, 341161, 345097, 368712, 369403, 288384, 340981, 319072, 374214, 344529, 337271,
281016, 282224, 320984, 325426, 366276, 380296, 300727, 359326, 327610, 383563, 352405, 329351, 294486,
333454, 334339, 358000, 396057, 386976, 307155, 363909, 344700, 397561, 376791, 337085, 299252, 323136,
329091, 346991, 461999, 436533, 360372, 415467, 382110, 432197, 424254, 386728, 354508, 375765, 367986,
402378, 426516, 433313, 338461, 416834, 381099, 445673, 412408, 393997, 348241, 380134, 373688, 393588,
434192, 430731, 344468, 411891, 370497, 437305, 411270, 385495, 341273, 384217, 373223, 415771, 448634,
454341, 350297, 419104, 398027, 456059, 430052, 399757, 362731, 384896, 385349, 432289, 468891, 442702,
370178, 439400, 393900, 468700, 438800, 430100, 366300, 391000, 380900, 431400, 465400, 471500, 387500,
446400, 421500, 504800, 492071, 421253, 396682, 428000, 421900, 465600, 525793, 499855, 435287, 479499,
473027, 554410, 489574, 462157, 420331]}

df = pd.DataFrame(data)
df['Data'] = pd.date_range(start='1980-01', periods=len(df), freq='M').strftime('%b-%y')
```

- a) Considere os períodos 1980:01-1993:06 e 1993:07-1995:06 como amostras de treino e teste, respetivamente. Ajuste aos dados da série observada no período de treino o método de Holt-Winters aditivo com $\alpha = 0.15$, $\beta = 0.2$ e $\gamma = 0.3$. Estabeleça previsões para o período de teste e calcule as medidas do erro quadrático médio (*EQM*) e erro percentual absoluto médio (*EPAM*).
- b) Repita o exercício anterior mas com pesquisa ótima das constantes de alisamento usando a biblioteca **statsmodels.tsa.holtwinters** do Python. Compare os resultados obtidos com o método anterior.
- c) Considere agora todo o período disponível e estabeleça previsões para os próximos 24 meses (1995:07-1997:06) com base na especificação com melhor acurácia preditiva.

Aula #2

Modelos ARMA, SARMA, ARIMA e SARIMA

Os modelos autoregressivos e de médias móveis (ARMA) e ARMA integrados (ARIMA) foram introduzidos por Box e Jenkins (1970, 1976) para modelar e prever séries temporais estacionárias e não estacionárias. Desenvolvimentos mais recentes encontram-se em Wei (2007), Box, Jenkins, Reinsel e Ljung (2015), Brockwell e Davis (2016), Hyndman e Athanasopoulos (2018), Tsay (2018), entre outros.

Esta classe de modelos desempenha um papel fundamental na caracterização da estrutura de algumas séries temporais observadas nas ciências económicas, financeiras e sociais.

Neste aula, introduz-se as formas funcionais dos:

- Modelos ARMA para séries estacionárias não sazonais,
- Modelos SARMA para séries estacionárias e puramente sazonais
- Modelos multiplicativos sazonais e não sazonais ARMA-SARMA
- Modelos ARIMA e SARIMA para séries não estacionárias

Estacionaridade, autocorrelação e autocorrelação parcial

Seja Y_t uma série temporal **estacionária** até à 2ª ordem, a **função autocovariância** do processo mede a intensidade com que covariam pares de valores de Y_t e Y_{t+k} separados por um intervalo de amplitude k e define-se por:

$$\gamma_k = Cov(Y_t, Y_{t+k}) = E[(Y_t - \mu)(Y_{t+k} - \mu)].$$

A **função de autocorrelação** (ACF) mede a correlação entre pares de valores da série desfasados em 1, 2 e mais períodos:

$$\rho_k = \frac{Cov(Y_t, Y_{t+k})}{\sqrt{[Var(Y_t)][Var(Y_{t+k})]}} = \frac{\gamma_k}{\gamma_0}.$$

Em termos práticos, a estacionaridade de uma série temporal observa-se quando os dados não apresentam tendência crescente ou decrescente nem apresentam movimentos periódicos e flutuam em torno de uma média contante, independente do tempo, e a variância das flutuações não se altera ao longo do tempo.

Para além de analisar a correlação total entre Y_t e Y_{t-k} , interessa também investigar a correlação simples entre Y_t e Y_{t-k} , depois de eliminar o efeito que sobre elas exercem os valores intermédios $Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}$, isto é: $\text{corr}(Y_t, Y_{t-k} | Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1})$. Esta correlação condicional na análise temporal designa-se por **autocorrelação parcial** (PACF) e representa-se por ϕ_{kk} . Em seguida, prova-se que ϕ_{kk} constitui o regressor de ordem k da regressão de Y_{t+k} sobre as variáveis $Y_{t+k-1}, Y_{t+k-2}, \dots, Y_t$.



No caso da função de autocorrelação (ACF), esta pode ser estimada através da expressão:

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2}, \quad k = 0, 1, 2, \dots$$

No caso da função de autocorrelação parcial (ACFP), a estimação pode ser feita através de um método recursivo, através da expressão:

$$\hat{\phi}_{kk} = \frac{\hat{\rho}_k - \sum_{j=1}^{k-1} \hat{\phi}_{k-1,j} \hat{\rho}_{k-j}}{1 - \sum_{j=1}^{k-1} \hat{\phi}_{k-1,j} \hat{\rho}_j},$$

com $\hat{\phi}_{11} = \hat{\rho}_1$ (inicialização) e $\hat{\phi}_{kj} = \hat{\rho}_{k-1,j} - \hat{\phi}_{kk} \hat{\phi}_{k-1,k-j}$, $j = 1, 2, \dots, k-1$.



Séries diárias dos preços de fecho, retornos e retornos ao quadrado das ações da Apple


Funções de autocorrelação (ACF) e autocorrelação parcial (PACF) das séries da Apple

Modelos autoregressivos (AR)


O modelo autoregressivo de 1ª ordem ou AR(1) tem a representação,

$$Y_t = \phi Y_{t-1} + \varepsilon_t,$$

onde ε_t é um ruído branco. Para que o processo seja estacionário deve satisfazer a condição $|\phi| < 1$. Um processo ruído branco (“white noise”) é constituído por uma série de valores não correlacionados ao longo do tempo de média zero, variância constante e covariância nula.



AR(1), $\phi = 0.7$ e respetivas ACF e PACF




AR(1), $\phi = -0.7$ e respetivas ACF e PACF

Modelo AR(2)


O modelo autoregressivo de 2ª ordem ou AR(2) tem a forma,

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t,$$

onde ε_t é um ruído branco. Para ser estacionário, tem que se verificar as condições: $\phi_2 + \phi_1 < 1 \wedge \phi_2 - \phi_1 < 1 \wedge -1 < \phi_2 < 1$. A ACF do modelo AR(2) tem decaimento exponencial ou sinusoidal amortecido para zero à medida que k aumenta, enquanto que a PACF tem uma queda brusca para zero a partir do lag 3 ($k \geq 3$).



AR(2), $(\phi_1, \phi_2) = (0.6, 0.3)$ e respectivas ACF e PACF




AR(2), $(\phi_1, \phi_2) = (-0.7, 0.2)$ e respectivas ACF e PACF

Modelo MA(1)


O modelo médias móveis de 1ª ordem ou MA(1) descreve a série Y_t através de um choque aleatório, ε_t , e também do seu valor desfasado um período, ε_{t-1} . Define-se através da relação,

$$Y_t = \varepsilon_t - \theta \varepsilon_{t-1},$$

onde ε_t é um ruído branco. O processo MA(1) é sempre estacionário, mas para ser um processo invertível, tem que satisfazer a condição $|\theta| < 1$. A ACF do modelo MA(1) tem uma queda brusca para zero a partir do *lag* 2 ($k \geq 2$), enquanto que a PACF tem um decaimento exponencial ou sinusoidal amortecido para zero quando k aumenta.



MA(1), $\theta = -0.75$ e respectivas ACF e PACF



MA(1), $\theta = 0.75$ e respectivas ACF e PACF

Modelo MA(2)

O modelo médias móveis de 2ª ordem ou MA(2) assume a expressão,

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2},$$


ε_t é um ruído branco. Para ser invertível, os coeficientes θ_1 e θ_2 têm que satisfazer as condições: $\theta_2 + \theta_1 < 1 \wedge \theta_2 - \theta_1 < 1 \wedge -1 < \theta_2 < 1$. A ACF do modelo MA(2) tem uma queda brusca para zero a partir do *lag* 3, enquanto que a PACF tem um decaimento exponencial ou sinusoidal amortecido para zero à medida que k aumenta.

Modelo ARMA


O modelo ARMA(1,1) inclui um fator autoregressivo de 1ª ordem e um fator de médias móveis de 1ª ordem e tem a representação,

$$Y_t = \phi Y_{t-1} + \varepsilon_t - \theta \varepsilon_{t-1}, \text{ com } \phi \neq \theta,$$

onde ε_t é um ruído branco. Para ser estacionário, $-1 < \phi < 1$. Para ser invertível, $-1 < \theta < 1$. Quer a ACF quer a PACF do modelo ARMA(1,1) tem um decaimento gradual (sem quedas bruscas) para zero à medida que k aumenta.



ARMA(1,1), $(\phi, \theta) = (0.85, -0.5)$ e respetivas ACF e PACF



ARMA(1,1), $(\phi, \theta) = (-0.4, 0.7)$ e respetivas ACF e PACF

Em geral, o modelo misto autoregressivo e médias móveis ARMA(p, q) tem a representação,

$$Y_t = \varphi_1 Y_{t-1} + \cdots + \varphi_p Y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q},$$


onde ε_t é um ruído branco.

Modelo ARMA sazonal (SARMA)


O modelo misto autoregressivo e de médias móveis estritamente sazonal de ordens P e Q , ou simplesmente modelo $\text{SARMA}(P,Q)_s$ tem a forma,

$$Y_t = \Phi_1 Y_{t-s} + \cdots + \Phi_P Y_{t-PS} + \varepsilon_t - \theta_1 \varepsilon_{t-s} - \cdots - \theta_Q \varepsilon_{t-Qs}, \text{ com } \Phi_P \neq 0 \text{ e } \theta_Q \neq 0,$$

onde ε_t é um ruído branco. Quer a ACF quer a PACF do modelo $\text{SARMA}(P,Q)_s$ apresentam um comportamento do tipo exponencial ou sinusoidal amortecido sobre os *lags* múltiplos de s , mantendo-se nulas nos restantes *lags*.



$\text{SARMA}(1,1)_{12}, (\Phi_1, \theta_1) = (0.65, -0.25)$, ACF e PACF




$\text{SARMA}(1,2)_4$ com $(\Phi_1, \theta_1, \theta_2) = (0.2, 0.5, 0.3)$, ACF e PACF

Modelo multiplicativo ARMA×SARMA

A combinação do modelo $\text{ARMA}(p,q)$ e $\text{SARMA}(P,Q)_s$ permite obter o modelo multiplicativo, com componente sazonal e não sazonal, $\text{SARMA}(p,q)(P,Q)_s$, através da expressão,

$$(1 - \phi_1 B - \dots - \phi_p B^p)(1 - \Phi_1 B^s - \dots - \Phi_P B^{Ps})Y_t = (1 - \theta_1 B - \dots - \theta_q B^q)(1 - \Theta_1 B^s - \dots - \Theta_Q B^{Qs})\varepsilon_t,$$

onde $B^j Y_t = Y_{t-j}$ e ε_t é um processo ruído branco. Para simplificar a notação, e como exemplo ilustrativo, considere-se o seguinte modelo multiplicativo $\text{SARMA}(1,0)(1,0)_{12}$: $(1 - 0.7B)(1 + 0.25B^{12})Y_t = \varepsilon_t$



Figurinos teóricos das FAC e FACP dos modelos de séries estacionárias

Modelo	FAC	FACP
AR(p)	Decaimento exponencial ou sinusoidal amortecido para zero	Queda brusca para zero a partir do lag $p+1$
MA(q)	Queda brusca para zero a partir do lag $q+1$	Decaimento exponencial ou sinusoidal amortecido para zero
ARMA(p,q)	Decaimento exponencial ou sinusoidal amortecido para zero	Decaimento exponencial ou sinusoidal amortecido para zero
SAR(P)	Decaimento exponencial ou sinusoidal amortecido para zero sobre os lags $s, 2s, \dots$	Queda brusca para zero a partir do lag $(P+1)s$
SMA(Q)	Queda brusca para zero a partir do lag $(Q+1)s$	Decaimento exponencial ou sinusoidal amortecido para zero sobre os lags $s, 2s, \dots$
SARMA(P,Q)	Decaimento exponencial ou sinusoidal amortecido para zero sobre os lags $s, 2s, \dots$	Decaimento exponencial ou sinusoidal amortecido para zero sobre os lags $s, 2s, \dots$
SARMA(p,q)(P,Q)_s	Decaimento exponencial ou sinusoidal amortecido para zero	Decaimento exponencial ou sinusoidal amortecido para zero

Diferenciação

A diferenciação simples de uma série temporal consiste em obter a diferença entre as observações da série nos momentos t e $t - 1$, isto é:

$$\nabla Y_t = Y_t - Y_{t-1}$$

ou, utilizando o já conhecido operador atraso ($BY_t = Y_{t-1}$),





$$\nabla Y_t = Y_t - Y_{t-1} = (1 - B)Y_t.$$

Operador de diferenciação de ordem d :

$$\nabla^d Y_t = (1 - B)^d Y_t$$

Operador de diferenciação sazonal de ordem D :

$$\nabla_s^D Y_t = (1 - B^s)^D Y_t$$



Estabilização da variância

Para estabilizar a variância de uma série não estacionária em variância, podemos utilizar um método de transformação paramétrica baseado na seguinte expressão:

$$X_t = T(Y_t) = \begin{cases} Y_t^\lambda, \lambda \neq 0 \\ \log(Y_t), \lambda = 0 \end{cases}$$

onde os valores de λ são escolhidos no intervalo $[-1,1]$, sendo os mais correntes -1 , -0.5 , 0 , 0.5 e 1 , a que correspondem as transformações $X_t = 1/Y_t$, $X_t = 1/\sqrt{Y_t}$, $X_t = \log Y_t$, $X_t = \sqrt{Y_t}$ e $X_t = Y_t$, respetivamente.

Algumas **considerações importantes** sobre as operações de estabilização da variância:

- A transformação de estabilização da variância, se for necessária, deve ser feita antes da transformação de estabilização da média (isto é, antes da diferenciação).
- A transformação de estabilização da variância só é aplicável a séries positivas.
- A escolha do valor adequado de λ deve ser feita de modo a minimizar uma das funções dos erros de previsão (erro quadrático médio, erro absoluto médio, erro percentual absoluto médio).


Modelo ARIMA

O modelo $ARIMA(p,d,q)$ assume a expressão:

$$(1 - \phi_1 B - \dots - \phi_p B^p)(1 - B)^d Y_t = (1 - \theta_1 B - \dots - \theta_q B^q) \varepsilon_t$$

As formas mais simples e frequentes do modelo ARIMA são $ARIMA(0,1,0)$, $ARIMA(1,1,0)$, $ARIMA(0,1,1)$ e $ARIMA(1,1,1)$. Por exemplo, a especificação $ARIMA(0,1,0)$ corresponde ao **modelo de passeio aleatório** (*random walk*):


$$Y_t = Y_{t-1} + \varepsilon_t.$$



Modelos SARIMA puro e multiplicativo

Podemos estender o modelo ARIMA a um **modelo puro** integrado sazonal representado simbolicamente por modelo $SARIMA(P,D,Q)_s$ ou a um **modelo multiplicativo** integrado sazonal representado simbolicamente por modelo $SARIMA(p,d,q)(P,D,Q)_s$. Por exemplo, o modelo $SARIMA(0,1,1)(0,1,1)_{12}$ tem a representação:

$$(1 - B)(1 - B^{12})Y_t = (1 - \theta_1 B)(1 - \Theta_1 B^{12})\varepsilon_t.$$



$SARIMA(0,1,1)(0,1,1)_{12}$, $\theta_1 = 0.6$ e $\Theta_1 = 0.3$ e as ACF e PACF

Aula #3

Metodologia de Modelação e Previsão ARIMA e SARIMA

Na análise de séries temporais, o investigador tem a preocupação de procurar o melhor modelo para descrever a relação existente entre as observações do fenómeno em estudo. Para atingir esse objetivo, é necessário ter um conhecimento profundo dos modelos estacionários e não estacionários apresentados nas duas secções anteriores, nomeadamente no que se refere às características das ACF e PACF.

Nesta secção, vai apresentar-se a metodologia de modelação ARIMA de séries temporais, que consiste nas etapas de:

- 1. Identificação dos modelos**
- 2. Estimação dos modelos**
- 3. Avaliação do diagnóstico**
- 4. Seleção de modelos**
- 5. Previsão**

1. Identificação

A primeira etapa de modelação de uma série temporal consiste na identificação de um modelo $SARIMA(p,d,q)(P,D,Q)_s$ que descreva a relação existente entre as suas observações.

Passo 1: Construção do cronograma da série e sua estacionarização

Representação gráfica (cronograma), estacionarização (transformações de estabilização da variância, eliminação da tendência e de movimentos de carácter periódico).



Passo 2: Estimação das ACF e PACF da série original

O comportamento das ACF e PACF estimadas com base na série original pode sugerir algumas transformações de diferenciação.

Passo 3: Estimação das ACF e PACF da série estacionária e identificação dos inteiros p , q , P e Q


Escolha dos modelos candidato a descrever a série em estudo, sendo fundamental no processo de identificação dos valores p , q , P e Q conhecer-se o comportamento das ACF e PACF teóricas dos modelos $ARMA(p,q)$ e $SARMA(p,q)(P,Q)_s$ mais usuais.

Exemplo de aplicação: Para ilustrar a modelação e previsão ARIMA, vamos usar o índice de preços no consumidor (IPC) nos Estados Unidos entre janeiro de 2020 e dezembro de 2024, num total de 180 observações mensais (fonte: FRED)



Teste ADF (taxa de inflação em níveis):
Estatística ADF statistic = -2.0782, valor-p = 0.2534
A taxa de inflação não é estacionária! Devemos aplicar diferenças.

Teste ADF (taxa de inflação em diferenças simples):
Estatística ADF statistic = -6.9550, valor-p = 0.0000
A primeira diferença da taxa de inflação é estacionária.



Possíveis modelos candidatos a descrever a série em estudo: $ARIMA(0,1,2)$, $ARIMA(1,1,1)$ e $ARIMA(4,1,0)$. Porquê? Justifique esta ou outras escolhas...

2. Estimação

Nesta fase, vai ser imprescindível o auxílio de um adequado *package* informático.

Método da máxima verosimilhança

Consiste em determinar os valores dos parâmetros que tornam mais verosímil a ocorrência de um conjunto de observações idênticas aquelas de que efetivamente se dispõe. Este método obtém estimativas dos parâmetros através de um processo iterativo em que se maximiza a função de verosimilhança dos estimadores (para mais detalhes veja-se Box, Jenkins, Reinsel e Ljung, 2015). Em geral, os programas informáticos de econometria de séries temporais começam por obter estimativas iniciais dos parâmetros, seguindo-se um processo iterativo até se obterem os valores ótimos dos parâmetros.

Método dos mínimos quadrados

Em modelos $ARMA(p,q)$ este método não permite obter estimadores consistentes com os verdadeiros parâmetros. Exceção feita nos casos em que se tem modelos com apenas componente autoregressiva (modelos $AR(p)$), em que os estimadores se podem obter por minimização da soma de quadrados dos resíduos.

3. Avaliação do diagnóstico

Esta etapa de avaliação do diagnóstico vai centrar-se fundamentalmente na análise dos resíduos do modelo estimado, que, de acordo com os pressupostos assumidos, devem ter um comportamento análogo a um ruído branco.

A avaliação da **qualidade estatística** das estimativas obtidas pode ser feita com base num teste parcial à hipótese nula de que cada parâmetro β_i é estatisticamente nulo:

$$|t| = \left| \frac{\hat{\beta}_i}{\sigma_{\hat{\beta}_i}} \right| > t_{(n-m)} \Rightarrow \text{Rejeitar } H_0: \beta_i = 0.$$

A avaliação da **qualidade do ajustamento** do modelo ARIMA pode ser feita com base no seguinte teste estatístico sobre a FAC residual estimada. Ljung e Box (1978) propuseram um teste para ensaiar a hipótese da nulidade global da FAC dos resíduos, $H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$, com base na estatística Q definida por:

$$Q = n(n+2) \sum_{j=1}^k \frac{\hat{\rho}_j^2}{n-j},$$

que tem aproximadamente uma distribuição do qui-quadrado com $k - m$ (numero de autocorrelações menos o número de parâmetros estimados) graus de liberdade.

Modelo ajustado ARIMA(0,1,2) para os dados de treino:

SARIMAX Results

```
=====
Dep. Variable:      inflation_rate    No. Observations:      167
Model:              ARIMA(0, 1, 2)    Log Likelihood         12.672
Date:              Sun, 12 Oct 2025    AIC                    -19.343
Time:              19:03:20            BIC                    -10.007
Sample:            02-01-2010          HQIC                   -15.554
                  - 12-01-2023
```

Covariance Type: opg

```
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
ma.L1        -0.4152     0.061     -6.809     0.000     -0.535    -0.296
ma.L2        -0.3994     0.064     -6.264     0.000     -0.524    -0.274
sigma2        0.0500     0.004     11.874     0.000      0.042     0.058
=====
```

```
Ljung-Box (L1) (Q):      0.01  Jarque-Bera (JB):      43.58
Prob(Q):                 0.93  Prob(JB):              0.00
Heteroskedasticity (H):   2.46  Skew:                 -0.64
Prob(H) (two-sided):      0.00  Kurtosis:              5.16
=====
```

Modelo ajustado ARIMA(1,1,1) para os dados de treino:

SARIMAX Results

```
=====
Dep. Variable:      inflation_rate    No. Observations:      167
Model:              ARIMA(1, 1, 1)    Log Likelihood         9.687
Date:              Sun, 12 Oct 2025    AIC                    -13.374
Time:              19:03:20            BIC                     -4.038
Sample:            02-01-2010          HQIC                   -9.584
                  - 12-01-2023
```

Covariance Type: opg

```
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
ar.L1         0.4383     0.074      5.922     0.000      0.293     0.583
ma.L1        -0.9328     0.026    -35.339     0.000     -0.985    -0.881
sigma2        0.0517     0.004     12.032     0.000      0.043     0.060
=====
```

```
Ljung-Box (L1) (Q):      0.57  Jarque-Bera (JB):      38.84
Prob(Q):                 0.45  Prob(JB):              0.00
Heteroskedasticity (H):   2.71  Skew:                 -0.55
Prob(H) (two-sided):      0.00  Kurtosis:              5.10
=====
```

Modelo ajustado ARIMA(4,1,0) para os dados de treino:

SARIMAX Results

```
=====
Dep. Variable:      inflation_rate    No. Observations:      167
Model:              ARIMA(4, 1, 0)    Log Likelihood         9.865
Date:              Sun, 12 Oct 2025    AIC                    -9.729
Time:              19:03:20            BIC                     5.831
Sample:            02-01-2010          HQIC                   -3.413
                  - 12-01-2023
```

Covariance Type: opg

```
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
ar.L1        -0.3659     0.064     -5.734     0.000     -0.491    -0.241
ar.L2        -0.4895     0.074     -6.596     0.000     -0.635    -0.344
ar.L3        -0.2938     0.069     -4.274     0.000     -0.429    -0.159
ar.L4        -0.1967     0.076     -2.581     0.010     -0.346    -0.047
sigma2        0.0518     0.005     11.447     0.000      0.043     0.061
=====
```

```
Ljung-Box (L1) (Q):      0.04  Jarque-Bera (JB):      69.66
Prob(Q):                 0.85  Prob(JB):              0.00
Heteroskedasticity (H):   2.67  Skew:                 -0.65
Prob(H) (two-sided):      0.00  Kurtosis:              5.90
=====
```

4. Seleção de modelos

Crítérios de seleção de modelos que tomem em consideração as estatísticas baseadas nos resíduos do modelo ajustado. Os critérios de seleção mais comuns são o AIC e o BIC.

Considere que um modelo com m parâmetros foi ajustado a uma série com n observações. Para avaliar a qualidade do ajustamento, Akaike (1974) introduziu um **critério baseado na quantidade de informação (AIC)**, definido por:

$$\text{AIC} = -2 \ln L + 2m,$$

onde L é a função de verosimilhança. Os *softwares* de estatística geralmente fornecem um valor aproximado do AIC, obtido através da expressão:

$$\text{AIC} = n \ln \widehat{\sigma}_{\hat{\varepsilon}}^2 + 2m,$$

onde $\widehat{\sigma}_{\hat{\varepsilon}}^2$ é a variância dos resíduos do modelo ARIMA ajustado. Segundo este critério, deve escolher-se como melhor modelo aquele que tenha um valor AIC menor.

Como alternativa ao AIC, Schwartz (1978) introduziu o seguinte **critério bayesiano (BIC)** de selecção de modelos:

$$\text{BIC} = n \ln \widehat{\sigma}_{\hat{\varepsilon}}^2 + m \ln n,$$

onde $\widehat{\sigma}_{\hat{\varepsilon}}^2$ é a variância dos resíduos, m o número de parâmetros do modelo e n o número de observações utilizadas na estimação do modelo. Na prática, deve também seleccionar-se o modelo que apresenta um valor BIC menor.

5. Previsão

Suponhamos que temos no momento T as observações $Y_T, Y_{T-1}, Y_{T-2}, \dots$ de uma série temporal e pretendemos, com base nestas, prever o valor futuro no momento $T + m, Y_{T+m}$. A previsão para o instante $T + m$ será função dos valores presentes e passados da série, isto é:

$$P_T(m) = E(Y_{T+m} | Y_T, Y_{T-1}, Y_{T-2}, \dots),$$


onde $P_T(m)$ é o preditor de Y_{T+m} , T é a origem da previsão e m é o horizonte da previsão. No que se refere ao horizonte temporal, o estabelecimento de previsões reveste-se de duas formas: previsão estática (passo-a-passo) e previsão dinâmica (a múltiplos passos à frente).

Por exemplo, no caso do modelo AR(1) estacionário, $Y_t = \phi Y_{t-1} + \varepsilon_t$, em que se utilizou as observações $t = 1, 2, \dots, T$ para a sua estimação. As previsões para horizontes temporais de 1, 2 e m períodos à frente são obtidas por:

$$P_T(1) = E(Y_{T+1} | Y_T, \dots, Y_1) = \phi Y_T,$$


$$P_T(2) = E(Y_{T+2} | Y_T, \dots, Y_1) = \phi P_{T+1} = \phi(\phi Y_T) = \phi^2 Y_T,$$

$$P_T(m) = E(Y_{T+m} | Y_T, \dots, Y_1) = \phi P_{T+m-1} = \phi(\phi^{m-1} Y_T) = \phi^m Y_T.$$



Resumo das métricas de desempenho preditivo:


	MSE	RMSE	MAE	MAPE(%)
ARIMA(0,1,2)	0.018	0.133	0.104	904.222
ARIMA(1,1,1)	0.025	0.158	0.124	1042.051
ARIMA(4,1,0)	0.014	0.120	0.100	732.465




Previsões para os próximos 12 períodos

2025-01-01	0.299702
2025-02-01	0.267099
2025-03-01	0.274874
2025-04-01	0.289863
2025-05-01	0.303175
2025-06-01	0.295458
2025-07-01	0.285891
2025-08-01	0.286172
2025-09-01	0.290268
2025-10-01	0.292985
2025-11-01	0.291869
2025-12-01	0.289713

Exemplo de aplicação: Para ilustrar a aplicação do **modelo SARIMA** a uma **série temporal com sazonalidade**, fomos recolher os dados da série mensal "RETAILSMNSA" das vendas a retalho nos EUA (US *retail sales, not seasonally adjusted*) entre janeiro de 2020 e dezembro de 2024.






```
Teste ADF - Série em níveis (treino):  
Estatística ADF = 1.1507, valor-p = 0.9956  
A série não é estacionária! Aplicar diferença sazonal (lag=12).
```

```
Teste ADF - Série com diferença sazonal (lag=12):  
Estatística ADF = -2.1047, valor-p = 0.2426  
A série ainda não é estacionária! Aplicar também diferença simples.
```

```
Teste ADF - Série com diferenças sazonal e simples:  
Estatística ADF = -4.1378, valor-p = 0.0008  
A série é estacionária após aplicar ambas as diferenças.
```



Quais os modelos ARIMA candidatos a descrever a série estaconarizada? Justifique a sua escolha.

Modelo ajustado SARIMA(0,1,2)(0,1,1)12 para os dados de treino:

SARIMAX Results

```
=====
Dep. Variable:      retail_sales    No. Observations:      156
Model:              ARIMA(0, 1, 2)x(0, 1, [1], 12)    Log Likelihood          -1589.926
Date:              Thu, 30 Oct 2025    AIC                    3187.852
Time:              12:21:23    BIC                    3199.703
Sample:            01-01-2010    HQIC                   3192.668
                  - 12-01-2022
```

Covariance Type: opg

```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ma.L1         -0.0588      0.039      -1.494      0.135      -0.136      0.018
ma.L2         -0.1075      0.024      -4.492      0.000      -0.154     -0.061
ma.S.L12       -0.1489      0.016     -9.189      0.000      -0.181     -0.117
sigma2        2.545e+08    2.54e-11     1e+19      0.000    2.55e+08    2.55e+08
=====
```

```
=====
Ljung-Box (L1) (Q):      0.79    Jarque-Bera (JB):      739.49
Prob(Q):                 0.37    Prob(JB):              0.00
Heteroskedasticity (H):  4.51    Skew:                  1.30
Prob(H) (two-sided):     0.00    Kurtosis:              13.83
=====
```

Modelo ajustado SARIMA(2,1,0)(3,1,0)12 para os dados de treino:

SARIMAX Results

```
=====
Dep. Variable:      retail_sales    No. Observations:      156
Model:              ARIMA(2, 1, 0)x(3, 1, 0, 12)    Log Likelihood          -1586.554
Date:              Thu, 30 Oct 2025    AIC                    3185.109
Time:              12:21:24    BIC                    3202.886
Sample:            01-01-2010    HQIC                   3192.333
                  - 12-01-2022
```

Covariance Type: opg

```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.L1         -0.0525      0.041     -1.282      0.200      -0.133      0.028
ar.L2         -0.1049      0.026     -3.987      0.000      -0.156     -0.053
ar.S.L12       -0.2016      0.026     -7.642      0.000      -0.253     -0.150
ar.S.L24       -0.1507      0.030     -5.073      0.000      -0.209     -0.092
ar.S.L36       -0.0637      0.026     -2.461      0.014      -0.114     -0.013
sigma2        2.595e+08    5.09e-11     5.1e+18      0.000    2.6e+08    2.6e+08
=====
```

```
=====
Ljung-Box (L1) (Q):      0.46    Jarque-Bera (JB):      714.29
Prob(Q):                 0.50    Prob(JB):              0.00
Heteroskedasticity (H):  4.47    Skew:                  1.40
Prob(H) (two-sided):     0.00    Kurtosis:              13.59
=====
```

Modelo ajustado SARIMA(1,1,1)(1,1,1)12 para os dados de treino:

SARIMAX Results

```
=====
Dep. Variable:      retail_sales    No. Observations:      156
Model:              ARIMA(1, 1, 1)x(1, 1, 1, 12)    Log Likelihood          -1589.012
Date:              Thu, 30 Oct 2025    AIC                    3188.024
Time:              12:21:24    BIC                    3202.839
Sample:            01-01-2010    HQIC                   3194.044
                  - 12-01-2022
```

Covariance Type: opg


```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.L1          0.6047      0.363      1.667      0.096      -0.106      1.316
ma.L1         -0.6855      0.351     -1.953      0.051      -1.373      0.002
ar.S.L12       0.4508      0.138      3.272      0.001      0.181      0.721
ma.S.L12       -0.6463      0.163     -3.972      0.000     -0.965     -0.327
sigma2        2.975e+08    4.51e-09     6.6e+16      0.000    2.98e+08    2.98e+08
=====
```


```
=====
Ljung-Box (L1) (Q):      0.42    Jarque-Bera (JB):      754.80
Prob(Q):                 0.51    Prob(JB):              0.00
Heteroskedasticity (H):  4.94    Skew:                  1.46
Prob(H) (two-sided):     0.00    Kurtosis:              13.87
=====
```

Resumo das métricas de desempenho preditivo:

	MSE	RMSE	MAE	MAPE(%)
SARIMA(0,1,2)(0,1,1)12	7.366014e+08	27140.401	22962.498	3.847
SARIMA(2,1,0)(3,1,0)12	4.647898e+08	21558.984	17945.741	3.014
SARIMA(1,1,1)(1,1,1)12	5.595903e+08	23655.660	20026.890	3.364

Melhor modelo segundo o critério MSE: SARIMA(2,1,0)(3,1,0)12





Aula #4

Modelos ARIMAX e SARIMAX com variáveis exógenas





Nesta secção vamos estender o conceito de modelos ARIMA para incluir **variáveis exógenas**, criando os chamados **modelos ARIMAX** (“AutoRegressive Integrated Moving Average with eXogenous variables”). O modelo $ARIMAX(p,d,q)$ adiciona variáveis exógenas X_t que podem influenciar Y_t , permitindo incorporar informação externa, económica ou financeira, como taxas de juros, PIB, desemprego ou preços de commodities.

A forma matricial do modelo ARIMAX é:


$$(1 - \phi_1 B - \dots - \phi_p B^p)(1 - B)^d Y_t = (1 - \theta_1 B - \dots - \theta_q B^q) \varepsilon_t + X_t \beta,$$

onde X_t é um vetor de **variáveis exógenas** no instante temporal t e β é um vetor de **coeficientes** que quantifica o impacto marginal de cada variável exógena sobre Y_t . A notação a usar é: $ARIMAX(p,d,q) + X_t \beta$.

A extensão do modelo ARIMAX ao **modelo SARIMAX**, que incorpora componentes sazonais na série temporal, é trivial. Neste caso, devemos usar a notação: $SARIMAX(p,d,q)(P,D,Q)_s + X_t \beta$.



Teste ADF à inflação: $ADF = -3.225$, Valor- $p = 0.0186$
Teste ADF à inflação em diferenças: $ADF = -6.312$, Valor- $p = 0.0000$



SARIMAX Results

```
=====
Dep. Variable:          INFLATION    No. Observations:          155
Model:                ARIMA(3, 0, 0)  Log Likelihood             28.898
Date:                Sun, 04 Jan 2026  AIC                           -41.796
Time:                19:58:24        BIC                           -17.448
Sample:              02-01-2010      HQIC                          -31.906
                  - 12-01-2022
```

Covariance Type: opg


```
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
const          0.5321     0.153      3.480     0.001     0.232     0.832
FEDFUNDS      -0.0642     0.054     -1.179     0.238    -0.171     0.043
UNRATE        -0.0479     0.021     -2.237     0.025    -0.090    -0.006
OIL            0.0086     0.001      8.819     0.000     0.007     0.011
ar.L1          0.4757     0.067      7.055     0.000     0.344     0.608
ar.L2         -0.0554     0.088     -0.631     0.528    -0.228     0.117
ar.L3          0.1851     0.082      2.253     0.024     0.024     0.346
sigma2         0.0402     0.004     10.676     0.000     0.033     0.048
=====
```

```
=====
Ljung-Box (L1) (Q):          0.15   Jarque-Bera (JB):          12.84
Prob(Q):                   0.70     Prob(JB):              0.00
Heteroskedasticity (H):      1.87     Skew:                 -0.05
Prob(H) (two-sided):         0.03     Kurtosis:             4.41
=====
```

Teste de Ljung-Box (resíduos do ARIMAX):

	lb_stat	lb_pvalue
1	0.148149	0.700310
2	0.393061	0.821576
3	1.810740	0.612601
4	2.077549	0.721498
5	6.614824	0.250898
6	8.141954	0.227887
7	8.142029	0.320237
8	11.066875	0.197939
9	11.250555	0.258925
10	13.968524	0.174432
11	15.175383	0.174608
12	15.792567	0.200923

Avaliação dos erros de previsão do modelo ARIMAX:
 $MSE=0.062$, $RMSE=0.250$, $MAE=0.225$, $MAPE=101.17\%$



Performing stepwise search to minimize bic

```
ARIMA(0,1,0)(0,0,0)[0] intercept : BIC=31.698, Time=0.03 sec
ARIMA(1,1,0)(0,0,0)[0] intercept : BIC=33.313, Time=0.03 sec
ARIMA(0,1,1)(0,0,0)[0] intercept : BIC=18.970, Time=0.05 sec
ARIMA(0,1,0)(0,0,0)[0] intercept : BIC=26.663, Time=0.02 sec
ARIMA(1,1,1)(0,0,0)[0] intercept : BIC=3.636, Time=0.16 sec
ARIMA(2,1,1)(0,0,0)[0] intercept : BIC=3.046, Time=0.14 sec
ARIMA(2,1,0)(0,0,0)[0] intercept : BIC=18.918, Time=0.05 sec
ARIMA(3,1,1)(0,0,0)[0] intercept : BIC=7.671, Time=0.19 sec
ARIMA(2,1,2)(0,0,0)[0] intercept : BIC=7.870, Time=0.28 sec
ARIMA(1,1,2)(0,0,0)[0] intercept : BIC=3.021, Time=0.14 sec
ARIMA(0,1,2)(0,0,0)[0] intercept : BIC=-1.812, Time=0.13 sec
ARIMA(0,1,3)(0,0,0)[0] intercept : BIC=2.998, Time=0.12 sec
ARIMA(1,1,3)(0,0,0)[0] intercept : BIC=8.065, Time=0.25 sec
ARIMA(0,1,2)(0,0,0)[0] intercept : BIC=-6.267, Time=0.04 sec
ARIMA(0,1,1)(0,0,0)[0] intercept : BIC=14.022, Time=0.03 sec
ARIMA(1,1,2)(0,0,0)[0] intercept : BIC=-1.343, Time=0.10 sec
ARIMA(0,1,3)(0,0,0)[0] intercept : BIC=-1.363, Time=0.05 sec
ARIMA(1,1,1)(0,0,0)[0] intercept : BIC=-0.517, Time=0.07 sec
ARIMA(1,1,3)(0,0,0)[0] intercept : BIC=3.655, Time=0.12 sec
```

Best model: ARIMA(0,1,2)(0,0,0)[0]

SARIMAX Results

```
=====
Dep. Variable:          y      No. Observations:      155
Model:                SARIMAX(0, 1, 2)      Log Likelihood      10.689
Date:                Sun, 04 Jan 2026      AIC      -15.378
Time:                20:02:58      BIC      -6.267
Sample:                02-01-2010      HQIC      -11.677
                   - 12-01-2022
```

Covariance Type: opg

```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ma.L1          -0.4049        0.063      -6.444      0.000      -0.528      -0.282
ma.L2          -0.4265        0.064      -6.688      0.000      -0.551      -0.301
sigma2          0.0506        0.004      11.664      0.000        0.042        0.059
=====
```

```
Ljung-Box (L1) (Q):                0.00      Jarque-Bera (JB):                46.72
Prob(Q):                          0.95      Prob(JB):                  0.00
Heteroskedasticity (H):              2.39      Skew:                      -0.69
Prob(H) (two-sided):                0.00      Kurtosis:                  5.32
=====
```

Warnings:

```
[1] Covariance matrix calculated using the outer product of gradients (complex-step)
Ordem ótima selecionada: SARIMAX(0, 1, 2)
```

```

=====
SARIMAX Results
=====
Dep. Variable:          INFLATION    No. Observations:          155
Model:                ARIMA(0, 1, 2)  Log Likelihood             32.740
Date:                 Sun, 04 Jan 2026  AIC                          -53.480
Time:                 20:02:58        BIC                          -35.258
Sample:               02-01-2010      HQIC                         -46.078
                   - 12-01-2022
Covariance Type:          opg
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
FEDFUNDS      -0.1153     0.044     -2.610     0.009     -0.202     -0.029
UNRATE        -0.0637     0.019     -3.411     0.001     -0.100     -0.027
OIL            0.0091     0.001      8.782     0.000      0.007      0.011
ma.L1         -0.6131     0.058    -10.511     0.000     -0.727     -0.499
ma.L2         -0.2299     0.069     -3.313     0.001     -0.366     -0.094
sigma2         0.0380     0.003     11.064     0.000      0.031      0.045
=====
Ljung-Box (L1) (Q):           0.10   Jarque-Bera (JB):           17.79
Prob(Q):                     0.75   Prob(JB):                  0.00
Heteroskedasticity (H):       1.79   Skew:                      -0.35
Prob(H) (two-sided):          0.04   Kurtosis:                   4.51
=====

```

```

Teste de Ljung-Box (resíduos do auto_arima (ARIMAX auto)):
      lb_stat  lb_pvalue
1      0.059588   0.807148
2      1.166659   0.558037
3      1.401792   0.705115
4      1.404387   0.843432
5      4.020083   0.546528
6      4.199168   0.649744
7      4.324160   0.741775
8      6.275778   0.616371
9      6.648185   0.673695
10     7.922544   0.636403
11     8.645420   0.654584
12     8.926898   0.709161

```

Avaliação dos erros de previsão do modelo ARIMAX auto:
MSE=0.041, RMSE=0.202, MAE=0.179, MAPE=134.34%




Tabela de previsões da inflação (%) – Cenário 7.1:

Data	Lim_inf	Previsão	Lim_sup	FEDFUNDS	UNRATE	OIL
2025-01-01	-0.059	0.308	0.675	4.48	4.1	0.24
2025-02-01	-0.098	0.294	0.685	4.48	4.1	0.24
2025-03-01	-0.102	0.294	0.689	4.48	4.1	0.24
2025-04-01	-0.106	0.294	0.693	4.48	4.1	0.24
2025-05-01	-0.110	0.294	0.697	4.48	4.1	0.24
2025-06-01	-0.114	0.294	0.701	4.48	4.1	0.24
2025-07-01	-0.118	0.294	0.705	4.48	4.1	0.24
2025-08-01	-0.122	0.294	0.709	4.48	4.1	0.24
2025-09-01	-0.125	0.294	0.713	4.48	4.1	0.24
2025-10-01	-0.129	0.294	0.716	4.48	4.1	0.24
2025-11-01	-0.133	0.294	0.720	4.48	4.1	0.24
2025-12-01	-0.136	0.294	0.724	4.48	4.1	0.24
2026-01-01	-0.140	0.294	0.727	4.48	4.1	0.24
2026-02-01	-0.144	0.294	0.731	4.48	4.1	0.24
2026-03-01	-0.147	0.294	0.735	4.48	4.1	0.24
2026-04-01	-0.151	0.294	0.738	4.48	4.1	0.24
2026-05-01	-0.154	0.294	0.742	4.48	4.1	0.24
2026-06-01	-0.158	0.294	0.745	4.48	4.1	0.24
2026-07-01	-0.161	0.294	0.749	4.48	4.1	0.24
2026-08-01	-0.165	0.294	0.752	4.48	4.1	0.24
2026-09-01	-0.168	0.294	0.755	4.48	4.1	0.24
2026-10-01	-0.172	0.294	0.759	4.48	4.1	0.24
2026-11-01	-0.175	0.294	0.762	4.48	4.1	0.24
2026-12-01	-0.178	0.294	0.766	4.48	4.1	0.24





Tabela de previsões da inflação (%) – Cenário 7.2:

	Lim_inf	Previsão	Lim_sup	FEDFUNDS	UNRATE	OIL
Data						
2025-01-01	0.009	0.376	0.743	4.33	3.5	2.206
2025-02-01	-0.094	0.298	0.690	4.57	3.6	-1.652
2025-03-01	-0.127	0.269	0.665	4.65	3.5	-4.627
2025-04-01	-0.017	0.383	0.782	4.83	3.4	8.418
2025-05-01	-0.227	0.177	0.580	5.06	3.6	-9.904
2025-06-01	-0.156	0.251	0.659	5.08	3.6	-1.858
2025-07-01	-0.061	0.350	0.761	5.12	3.5	8.287
2025-08-01	-0.108	0.307	0.722	5.33	3.7	6.989
2025-09-01	-0.090	0.329	0.748	5.33	3.8	9.878
2025-10-01	-0.234	0.189	0.611	5.33	3.9	-4.233
2025-11-01	-0.274	0.153	0.579	5.33	3.7	-9.288
2025-12-01	-0.266	0.164	0.594	5.33	3.8	-7.447
2026-01-01	-0.163	0.271	0.704	5.33	3.7	3.133
2026-02-01	-0.169	0.268	0.706	5.33	3.9	4.176
2026-03-01	-0.163	0.278	0.719	5.33	3.9	5.216
2026-04-01	-0.168	0.276	0.721	5.33	3.9	5.007
2026-05-01	-0.284	0.164	0.612	5.33	4.0	-6.237
2026-06-01	-0.238	0.214	0.665	5.33	4.1	-0.321
2026-07-01	-0.220	0.235	0.690	5.33	4.2	2.549
2026-08-01	-0.307	0.151	0.610	5.33	4.2	-6.256
2026-09-01	-0.307	0.155	0.616	5.13	4.1	-8.408
2026-10-01	-0.181	0.284	0.749	4.83	4.1	2.490
2026-11-01	-0.224	0.244	0.713	4.64	4.2	-2.827
2026-12-01	-0.178	0.294	0.766	4.48	4.1	0.240



Exercícios

1. Utilize um modelo ARIMA para prever o índice S&P 500 nos próximos 12 meses.
 - a) Obtenha o Índice S&P500 a partir da base de dados FRED e representar graficamente a série temporal.
 - b) Realize o teste de raízes unitárias de ADF (Augmented Dickey-Fuller) para verificar se a série é estacionária. Se for não estacionária, aplique primeiras diferenças para a tornar estacionária.
 - c) Ajuste um modelo ARIMA à série estacionária e avalie a qualidade estatística e de ajustamento.
 - d) Efetue previsões para os próximos 12 meses com o modelo ajustado e representar graficamente as previsões, incluindo os intervalos de confiança.

2. Usando a série “IPG2211A2N” da produção mensal de energia elétrica nos EUA entre janeiro de 2010 e dezembro de 2024 (fonte: FRED), construa um código em Python para dar resposta às seguintes questões:

- a)** Importe os dados, construa um gráfico da série original e comente o seu comportamento.
- b)** Faça a divisão em conjunto de treino e em conjunto de teste (últimas 12 observações). Aplique o teste de Augmented Dickey-Fuller (ADF) sobre a série em níveis no conjunto de treino.
- c)** Se a série for não estacionária, aplique primeiro uma diferença sazonal e testa de novo. Se ainda assim for não estacionária, aplica uma diferença simples sobre a série já diferenciada sazonalmente.
- d)** Construa os correlogramas (ACF e PACF) da serie estacionária e identifica potenciais modelos SARIMA candidatos à descrever a série.
- e)** Estime os respetivos modelos e avalie as suas qualidades estatística e de ajustamento. Escolha o melhor à luz do critério de ajustamento AIC e o melhor à luz do critério de previsão MSE. Reajuste este último modelo aos dados da série completa e efetue previsões para os próximos 12 meses.


Aula #5

Redes Neuronais Convolucionais (CNN), Redes Neuronais Recorrentes (RNN), Memória de Curto Prazo Longa (LSTM) e Unidade Recorrente com Portas (GRU)

O que é uma rede neuronal?

As redes neuronais artificiais são compostas por unidades básicas chamadas neurónios (ou nós), que estão organizadas em múltiplas camadas (layers), para extrair padrões e aprender representações complexas dos dados.

Uma rede neuronal tem pelo menos três tipos de camadas: **camada de entrada**, **camadas ocultas** e **camada de saída**.



Treino de uma rede neuronal clássica

O treino de uma rede neuronal envolve o ajustamento dos pesos das conexões entre os neurónios de modo a que o modelo aprenda a mapear corretamente as entradas para as saídas desejadas. O processo de treino geralmente envolve os seguintes passos:

Passo 1: **Inicialização dos pesos**

Passo 2: **Propagação direta (*forward propagation*)**

Passo 3: **Cálculo do erro**

Passo 4: **Retropropagação (*backward propagation*)**

Passo 5: **Atualização dos pesos**

Passo 6. **Processo iterativo (épocas)**

Repetição dos passos 2 a 5 (propagação direta, cálculo do erro, retropropagação e atualização dos pesos) por várias **iterações** ou **épocas**, até que a rede consiga convergir para um conjunto de pesos que minimizem o erro de previsão ou classificação.

Introdução às redes neuronais convolucionais

As redes neuronais convolucionais (CNN) surgiram da necessidade de criar modelos capazes de processar dados estruturados em forma de grelha, como imagens ou sinais temporais, de forma eficiente.

Com o tempo, os investigadores começaram a explorar a sua aplicação em outros domínios para além de imagens, nomeadamente em **dados sequenciais**, como séries temporais e sinais de áudio. Ao adaptar as convoluções de duas para uma dimensão, foi possível capturar padrões locais no tempo, abrindo caminho para a utilização dos CNN em problemas de previsão, reconhecimento de fala e análise de sinais biomédicos.

A convolução é a operação central que dá nome às redes neuronais convolucionais.

De forma matemática, a convolução de duas funções contínuas $f(t)$ e $g(t)$ é definida como $(f * g)(t) = \int_{-\infty}^{+\infty} f(\tau)g(t - \tau)d\tau$. No contexto digital e discreto, utilizado em aprendizagem automática, esta operação traduz-se numa soma ponderada de valores de entrada com os pesos de um filtro. Por exemplo, numa série temporal unidimensional, a convolução entre a sequência de entrada x e um kernel w de tamanho k pode ser escrita como $y_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i}$. A ideia fundamental é que um mesmo conjunto de pesos (o filtro) seja aplicado a diferentes partes da entrada, permitindo à rede detectar padrões locais recorrentes.

As **camadas de entrada** (*input layers*) estabelecem qual a forma e o tamanho dos dados a serem processados pela rede.

As **camadas convolucionais** (*convolutional layers*) aplicam os filtros (*kernels*) à entrada, gerando mapas de características que representam os padrões extraídos.

As **camadas de pooling** (*pooling layers*) servem para reduzir a dimensionalidade dos dados, retendo apenas a informação mais relevante e tornando a rede mais robusta a variações locais.

As **camadas densas** (*fully connected layers*) ligam todos os neurónios de uma camada a todos os neurónios da camada seguinte.

Por fim, a **camada de saída** (*output layer*) fornece a saída final.





Ilustração de uma rede neuronal convolucional (CNN)

O que é a camada de convolução (*convolutional layer*)?

Aplicam-se filtros aos dados de entrada para detetar características na sequência de dados



Source: <https://www.ibm.com/cloud/learn/convolutional-neural-networks>

CNN para séries temporais

A adaptação das convoluções para séries temporais envolve essencialmente:

- **Conv1D**, onde o kernel desliza ao longo de uma dimensão temporal, em vez de duas dimensões espaciais.
- Cada filtro aprende a detectar **padrões locais** na sequência, como tendências curtas, oscilações ou picos periódicos.
- Ao combinar várias camadas convolucionais, a rede consegue construir **representações hierárquicas**: padrões simples nas primeiras camadas e combinações mais complexas nas camadas mais profundas.

Vantagens das CNN em séries temporais:

- **Paralelização do treino**: ao contrário das redes recorrentes (RNN e LSTM), que processam os dados ponto a ponto, as CNN podem processar várias janelas simultaneamente, tornando o treino muito mais rápido.
- **Capturam padrões locais**, o que é útil quando dependências de curto e médio prazo são mais importantes que dependências de longo prazo.
- **Usam janelas de entrada fixas**, o que significa que não capturam diretamente padrões que se estendem além do tamanho da janela.

Limitação: Têm dificuldades em modelar **dependências de longo prazo** sem combinações com outras arquiteturas, como o LSTM.

Implementações das CNN em Python

Exemplo de aplicação: Preços históricos de fecho diários das ações da Apple (2:1:2018-30:12:2023, 1259 observações diárias)

Etapa 1: Preparação dos dados

Em séries temporais, é comum criar **janelas deslizantes** que transformam a sequência original em pares (X, y), onde X é a sequência de entrada de tamanho fixo e y é o valor seguinte a prever.

```
import pandas_datareader.data as web
import yfinance as yf
# Importar a série temporal (preço das ações da Apple (AAPL))
ticker = "AAPL"
start = "2018-01-01"
end = "2023-01-01"
df = yf.download(ticker, start=start, end=end)
#df = web.DataReader(ticker, 'yahoo', start, end)
#df = web.DataReader(ticker, 'stooq', start, end)
prices = df["Close"]
print(prices)
```



Etapa 2: Definição do modelo CNN 1D

Uma CNN básica para séries temporais geralmente inclui: **camadas convolucionais 1D** (Conv1D), **camadas de pooling** (MaxPooling1D ou AveragePooling1D) e **camadas densas** (Dense).

Model: "sequential_13"

Layer (type)	Output Shape	Param #
conv1d_8 (Conv1D)	(None, 18, 32)	128
max_pooling1d_7 (MaxPooling1D)	(None, 9, 32)	0
flatten_6 (Flatten)	(None, 288)	0
dense_20 (Dense)	(None, 50)	14,450
dense_21 (Dense)	(None, 1)	51

Total params: 14,629 (57.14 KB)

Trainable params: 14,629 (57.14 KB)

Non-trainable params: 0 (0.00 B)

Como interpretar o modelo CNN 1D?

Etapa 3: Treino e avaliação


Após definir a rede, treinamos o modelo com a função fit, separando uma parte dos dados para validação (**validation_split=0.2**).

```
Epoch 1/10
25/25 ————— 0s 6ms/step - loss: 5.5606e-04 - val_loss: 0.0015
Epoch 2/10
25/25 ————— 0s 5ms/step - loss: 5.5519e-04 - val_loss: 9.3976e-04
Epoch 3/10
25/25 ————— 0s 5ms/step - loss: 4.8856e-04 - val_loss: 0.0013
Epoch 4/10
25/25 ————— 0s 5ms/step - loss: 4.7494e-04 - val_loss: 9.1873e-04
Epoch 5/10
25/25 ————— 0s 5ms/step - loss: 4.1963e-04 - val_loss: 7.6897e-04
Epoch 6/10
25/25 ————— 0s 5ms/step - loss: 4.4747e-04 - val_loss: 7.0606e-04
Epoch 7/10
25/25 ————— 0s 5ms/step - loss: 4.1500e-04 - val_loss: 6.0804e-04
Epoch 8/10
25/25 ————— 0s 5ms/step - loss: 3.2994e-04 - val_loss: 6.0673e-04
Epoch 9/10
25/25 ————— 0s 5ms/step - loss: 3.5445e-04 - val_loss: 0.0013
Epoch 10/10
25/25 ————— 0s 5ms/step - loss: 3.3208e-04 - val_loss: 6.8789e-04
8/8 ————— 0s 4ms/step - loss: 0.0016
Loss (MSE) no conjunto de teste: 0.0015
8/8 ————— 0s 4ms/step
```


Modelo CNN 1D
RMSE: 5.60
MAPE: 3.03%

Como interpretar os erros
do modelo CNN 1D?


Etapa 4: Visualização das previsões



Etapa 5: Previsão de valores futuros



Exemplo de aplicação: Preço médio de venda de casas nos EUA (ASPUS) entre o 1º trimestre de 1963 e o 2º trimestre de 2025 (Fonte: <https://fred.stlouisfed.org/series/ASPUS>, U.S. Census Bureau, U.S. Department of Housing and Urban Development via FRED).



Date	Price
1963-01-01	19300
1963-04-01	19400
1963-07-01	19200
1963-10-01	19600
1964-01-01	19600
...	...
2024-04-01	502200
2024-07-01	498700
2024-10-01	510900
2025-01-01	514200
2025-04-01	512800

[250 rows x 1 columns]

CNN simples

Modelo CNN simples:

Model: "sequential_23"

Layer (type)	Output Shape	Param #
conv1d_22 (Conv1D)	(None, 6, 32)	128
max_pooling1d_19 (MaxPooling1D)	(None, 3, 32)	0
flatten_16 (Flatten)	(None, 96)	0
dense_42 (Dense)	(None, 50)	4,850
dense_43 (Dense)	(None, 1)	51

Total params: 15,089 (58.95 KB)

Trainable params: 5,029 (19.64 KB)

Non-trainable params: 0 (0.00 B)

Optimizer params: 10,060 (39.30 KB)

CNN mais complexo

Modelo CNN mais complexo:

Model: "sequential_24"

Layer (type)	Output Shape	Param #
conv1d_23 (Conv1D)	(None, 8, 64)	256
conv1d_24 (Conv1D)	(None, 8, 64)	12,352
max_pooling1d_20 (MaxPooling1D)	(None, 4, 64)	0
dropout_9 (Dropout)	(None, 4, 64)	0
conv1d_25 (Conv1D)	(None, 4, 128)	24,704
max_pooling1d_21 (MaxPooling1D)	(None, 2, 128)	0
dropout_10 (Dropout)	(None, 2, 128)	0
flatten_17 (Flatten)	(None, 256)	0
dense_44 (Dense)	(None, 100)	25,700
dropout_11 (Dropout)	(None, 100)	0
dense_45 (Dense)	(None, 50)	5,050
dense_46 (Dense)	(None, 1)	51

Total params: 204,341 (798.21 KB)

Trainable params: 68,113 (266.07 KB)

Non-trainable params: 0 (0.00 B)

Optimizer params: 136,228 (532.14 KB)

Comparação dos modelos

Resultados do CNN simples:

RMSE: 26415.48


MAPE: 5.03%

Resultados do modelo CNN mais complexo:


RMSE: 108058.09

MAPE: 24.87%

Previsões com o CNN simples
RMSE=30246.9, MAPE=4.7%



Previsões com o CNN complexo
RMSE=90996.9, MAPE=20.5%



Redes Neurais Recorrentes

As redes neurais recorrentes (*Recurrent Neural Networks* ou RNN) surgem como uma extensão natural das redes neurais tradicionais para lidar com **dados sequenciais** pois as séries temporais apresentam dependências temporais...

As RNN foram concebidas precisamente para capturar essas relações ao longo do tempo, incorporando uma noção de **memória** no processo de aprendizagem.

Como funciona na prática?


Para cada elemento da uma sequência de dados, a RNN recebe a informação atual (entrada), chamada de "**estado oculto**", que é a memória do instante anterior. Essa informação é então processada e usada para calcular a saída atual e obter um novo estado oculto.

A fórmula de cálculo do estado oculto da RNN em cada instante temporal t é dada por:

$$h_t = f_w(x_t, h_{t-1}, b_h),$$

onde h_t é o novo estado, f_w é uma função de ativação, x_t é o input no instante t , h_{t-1} é o estado antigo ou estado oculto no instante anterior, e b_h é o vetor de *bias* (ou ajustamento) da camada oculta.


Arquitetura da RNN



Source: [GitHub - Azure/DeepLearningForTimeSeriesForecasting: A tutorial demonstrating how to implement deep learning models for time series forecasting](#)

Memória de curto prazo longa (LSTM)

A primeira variante a ganhar destaque foi a Long Short-Term Memory (LSTM). As LSTM utilizam células de memória e três portas principais: a porta de entrada (*input gate*), a porta de esquecimento (*forget gate*) e a porta de saída (*output gate*). Esta arquitetura permite que o modelo retenha informação por períodos mais longos.



Fonte: Wikipedia, LSTM

Como funciona na prática?

O LSTM funciona em três passos principais num determinado *time step* t :

Passo 1: Decidir que informação do passado deve ser mantida

$$\begin{aligned}f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f) \\c'_t &= f_t \odot c_{t-1}\end{aligned}$$

Passo 2: Determinar que novas informações devem entrar na célula


$$\begin{aligned}i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i) \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\ c_t &= c'_t + i_t \odot \tilde{c}_t\end{aligned}$$

Passo 3: Calcular a saída a partir do estado da célula

$$\begin{aligned}o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o) \\ h_t &= o_t \odot \tanh(c_t)\end{aligned}$$

Unidade Recorrente com Portas (GRU)

Os Gated Recurrent Units (GRU) são uma versão simplificada das LSTM. Apesar de mais leves em termos computacionais, os GRU mantêm a capacidade de controlar o fluxo de informação através de duas portas principais: a **porta de atualização** e a **porta de redefinição**.



Fonte: Wikipedia, GRU

Implementação em Python de RNN, LSTM e GRU

Exemplo de aplicação: Dados dos preços diários de fecho das ações da Apple (AAPL), disponíveis através da biblioteca yfinance.

Passo 1: Preparação dos dados e importação das bibliotecas do Python



Passo 2: Implementação do RNN Simples

```
# Modelo RNN Simples
model_rnn = Sequential([
    SimpleRNN(50, activation="tanh", input_shape=(window_size, n_features)), Dense(1)])
model_rnn.compile(optimizer="adam", loss="mse")
model_rnn.fit(X_train, y_train, epochs=20, batch_size=32,
              validation_split=0.2, verbose=0)
y_pred_rnn = model_rnn.predict(X_test)
y_pred_rnn_inv = scaler.inverse_transform(y_pred_rnn)
y_test_inv = scaler.inverse_transform(y_test.reshape(-1,1))

rmse_rnn = np.sqrt(mean_squared_error(y_test_inv, y_pred_rnn_inv))
mape_rnn = np.mean(np.abs((y_test_inv - y_pred_rnn_inv) / y_test_inv)) * 100
print("Modelo RNN")
print(f"RMSE: {rmse_rnn:.2f}, MAPE: {mape_rnn:.2f}%")
```

```
Modelo RNN
RMSE: 7.24, MAPE: 3.94%
```

Passo 3: Implementação do LSTM

```
# Modelo LSTM
model_lstm = Sequential([
    LSTM(50, activation="tanh", input_shape=(window_size, n_features)),
    Dense(1)
])
model_lstm.compile(optimizer="adam", loss="mse")
model_lstm.fit(X_train, y_train, epochs=20, batch_size=32,
               validation_split=0.2, verbose=0)
y_pred_lstm = model_lstm.predict(X_test)
y_pred_lstm_inv = scaler.inverse_transform(y_pred_lstm)
y_test_inv = scaler.inverse_transform(y_test.reshape(-1,1))
rmse_lstm = np.sqrt(mean_squared_error(y_test_inv, y_pred_lstm_inv))
mape_lstm = np.mean(np.abs((y_test_inv - y_pred_lstm_inv) / y_test_inv)) * 100
print("Modelo LSTM")
print(f"RMSE: {rmse_lstm:.2f}, MAPE: {mape_lstm:.2f}%")
```

```
Modelo LSTM
RMSE: 6.70, MAPE: 3.51%
```


Passo 4: Implementação do GRU

```
# Modelo GRU
model_gru = Sequential([
    GRU(50, activation="tanh", input_shape=(window_size, n_features)),
    Dense(1)
])
model_gru.compile(optimizer="adam", loss="mse")
model_gru.fit(X_train, y_train, epochs=20, batch_size=32,
              validation_split=0.2, verbose=0)


y_pred_gru = model_gru.predict(X_test)
y_pred_gru_inv = scaler.inverse_transform(y_pred_gru)
y_test_inv = scaler.inverse_transform(y_test.reshape(-1,1)) #já foi criado em LSTM
rmse_gru = np.sqrt(mean_squared_error(y_test_inv, y_pred_gru_inv))
mape_gru = np.mean(np.abs((y_test_inv - y_pred_gru_inv) / y_test_inv)) * 100
print("Modelo GRU")
print(f"RMSE: {rmse_gru:.2f}, MAPE: {mape_gru:.2f}%")
```

```
Modelo GRU
RMSE: 4.23, MAPE: 2.26%
```

Passo 5: Comparação visual de modelos



Passo 6: Previsão de valores futuros com o melhor modelo



Modelos RNN, LSTM e GRU com variáveis exógenas




Nos exercícios anteriores, os modelos de redes neuronais recorrentes (RNN simples, LSTM e GRU) foram aplicados num **contexto univariado**, utilizando exclusivamente a informação histórica do preço de fecho das ações da Apple.

Contudo, nos mercados financeiros, o preço de um ativo é influenciado por um conjunto alargado de fatores observáveis que não se refletem necessariamente de forma imediata ou completa no histórico da variável alvo.

A inclusão de **variáveis exógenas** permite estender o problema para um **contexto multivariado**, no qual a variável target (preço de fecho) é explicada não apenas pelo seu passado, mas também por outras séries temporais observadas em simultâneo.

Em seguida, vamos ilustrar a aplicação dos modelos de redes neuronais recorrentes com a inclusão das seguintes variáveis exógenas:


- **Volume de negociação** (volume), usando como proxy da liquidez e interesse do mercado;
- **Amplitude da cotação diária** (range) (preço máximo menos o preço mínimo do dia), usada como medida de volatilidade intradiária;
- **Retorno diário** (return), capturando a oportunidade de investimento no curto prazo.



Date	Open	High	Low	Close	Volume	Range	Return
2018-01-03	40.544	41.014	40.406	40.472	125393932	0.608	-0.000
2018-01-04	40.545	40.766	40.436	40.664	95104622	0.330	0.005
2018-01-05	40.758	41.214	40.670	41.122	100413538	0.544	0.011
2018-01-08	40.971	41.268	40.875	40.981	87365935	0.393	-0.003
2018-01-09	41.014	41.138	40.750	40.965	91633457	0.388	-0.000
...	...	...	...	...	...	...	...
2022-12-23	129.414	130.893	128.150	130.345	64556865	2.743	-0.003
2022-12-27	129.869	129.899	127.240	128.536	69810179	2.659	-0.014
2022-12-28	128.180	129.522	124.423	124.591	86431778	5.099	-0.031
2022-12-29	126.519	128.981	126.262	128.120	76583912	2.719	0.028
2022-12-30	126.933	128.457	125.967	128.437	77929881	2.490	0.002

[1258 rows x 7 columns]

Comparação das previsões dos modelos RNN, LSTM e GRU com exógenas (Apple)



Modelo RNN multivariado
RMSE: 6.52, MAPE: 3.45%


Modelo LSTM multivariado
RMSE: 4.14 MAPE: 2.25%

Modelo GRU multivariado
RMSE: 3.91, MAPE: 2.08%

Cenário 1: Previsões da Apple com exógenas iguais ao último instante observado				
	Predicted_Close	Volume	Range	Return
Date				
2023-01-02	129.643005	77929881.0	2.49	0.002
2023-01-03	129.973007	77929881.0	2.49	0.002
2023-01-04	130.373001	77929881.0	2.49	0.002
2023-01-05	130.807007	77929881.0	2.49	0.002
2023-01-06	131.253998	77929881.0	2.49	0.002
2023-01-09	131.705994	77929881.0	2.49	0.002
2023-01-10	132.158005	77929881.0	2.49	0.002
2023-01-11	132.608002	77929881.0	2.49	0.002
2023-01-12	133.057007	77929881.0	2.49	0.002
2023-01-13	133.503998	77929881.0	2.49	0.002
2023-01-16	133.949005	77929881.0	2.49	0.002
2023-01-17	134.393005	77929881.0	2.49	0.002
2023-01-18	134.837006	77929881.0	2.49	0.002
2023-01-19	135.279007	77929881.0	2.49	0.002
2023-01-20	135.720993	77929881.0	2.49	0.002
2023-01-23	136.160995	77929881.0	2.49	0.002
2023-01-24	136.600006	77929881.0	2.49	0.002
2023-01-25	137.037994	77929881.0	2.49	0.002
2023-01-26	137.473999	77929881.0	2.49	0.002
2023-01-27	137.908997	77929881.0	2.49	0.002
2023-01-30	138.343002	77929881.0	2.49	0.002
2023-01-31	138.774002	77929881.0	2.49	0.002
2023-02-01	139.203995	77929881.0	2.49	0.002
2023-02-02	139.632996	77929881.0	2.49	0.002
2023-02-03	140.059006	77929881.0	2.49	0.002
2023-02-06	140.483994	77929881.0	2.49	0.002
2023-02-07	140.906998	77929881.0	2.49	0.002
2023-02-08	141.326996	77929881.0	2.49	0.002
2023-02-09	141.746002	77929881.0	2.49	0.002
2023-02-10	142.162003	77929881.0	2.49	0.002

Cenário 2: Previsões da Apple com exógenas iguais ao período de teste				
	Predicted_Close	Volume	Range	Return
Date				
2023-01-02	129.643005	64964928.0	2.550	-0.008
2023-01-03	129.772995	81324082.0	5.269	0.013
2023-01-04	130.082993	75699612.0	2.699	0.004
2023-01-05	130.584000	59406851.0	2.627	-0.022
2023-01-06	130.371994	52406455.0	3.457	0.015
2023-01-09	130.832001	58979261.0	2.464	0.006
2023-01-10	131.391998	35605080.0	1.740	-0.020
2023-01-11	131.410995	70152809.0	3.224	-0.026
2023-01-12	131.031998	84737719.0	4.404	-0.021
2023-01-13	130.845001	112675898.0	8.075	0.049
2023-01-16	131.669998	72078840.0	2.491	0.002
2023-01-17	132.460007	66208399.0	2.323	-0.003
2023-01-18	132.391006	69626682.0	5.091	-0.008
2023-01-19	132.011002	65479765.0	5.319	-0.025
2023-01-20	131.416000	70531737.0	3.328	-0.014
2023-01-23	131.266998	62850700.0	2.393	0.012
2023-01-24	131.809006	76981786.0	4.617	-0.003
2023-01-25	131.940994	71281919.0	3.404	0.016
2023-01-26	132.591995	94977769.0	5.664	0.007
2023-01-27	132.664001	83247976.0	5.433	-0.016
2023-01-30	132.195999	100082182.0	5.707	-0.047
2023-01-31	130.804001	162019034.0	3.874	-0.015
2023-02-01	130.197998	80518032.0	3.837	-0.016
2023-02-02	130.237000	78333125.0	3.321	-0.001
2023-02-03	130.697006	86927072.0	4.012	0.024
2023-02-06	131.589005	78757289.0	4.211	-0.024
2023-02-07	131.459000	64556865.0	2.743	-0.003
2023-02-08	131.679993	69810179.0	2.659	-0.014
2023-02-09	131.738998	86431778.0	5.099	-0.031
2023-02-10	131.173996	76583912.0	2.719	0.028

Previsão futura com o melhor modelo de previsão: modelo GRU



Comparação dos Modelos: Vantagens e Limitações

Modelo	Vantagens	Limitações
RNN	Simples de implementar; capta dependências temporais básicas; boa para sequências curtas.	Problemas de desvanecimento/explosão do gradiente; treino lento; difícil em séries longas.
LSTM	Retém dependências de longo prazo; controla fluxo de informação com portas; robusta.	Mais complexa e pesada computacionalmente; menor paralelização que CNN/Transformers.
GRU	Estrutura mais simples que LSTM; treina mais rápido; desempenho próximo ou igual ao LSTM.	Menos interpretável que LSTM; pode perder desempenho em séries com padrões muito longos.
CNN	Boa paralelização; capta padrões locais e de curto/médio prazo; rápido a treinar.	Menos eficaz em dependências de longo prazo; precisa de muitas camadas para contexto extenso.



Obrigado

Jorge Caiado

jcaiado@iseg.ulisboa.pt

Triple Crown Accreditation



Top 40
Worldwide
Knowledge to Shape the Future



**EXECUTIVE
EDUCATION**